

- 基于 Qwen2.5-VL 的智能图文问答助手设计与实现
- 第一章 绪论
 - 1.1 研究背景
 - 1.2 项目目标
 - 1.3 技术路线
- 第二章 相关技术介绍
 - 2.1 视觉问答 (VQA)
 - 2.2 Qwen2.5-VL 模型
 - 2.3 Flask 框架
 - 2.4 Transformers
- 第三章 系统设计
 - 3.1 系统总体架构
 - 图像输入模块
 - 会话管理模块
 - 模型推理模块
 - 前端展示模块
 - 3.2 多轮对话设计
 - 3.3 图片管理机制
 - 3.4 系统流程
- 第四章 系统实现
 - 4.1 模型加载
 - 4.2 Prompt构建与多模态输入实现
 - 4.3 图文问答实现
 - 4.3 Web交互实现
 - 4.4 评测脚本实现
 - 4.5 推理优化与显存管理
 - (1) 自动设备映射
 - (2) 推理模式运行
 - (3) 缓存释放
- 第五章 实验设计与结果分析
 - 5.1 实验环境
 - 5.2 数据集与实验设置
 - VQA-v2
 - TextVQA
 - 5.3 实验结果
 - 5.4 结果分析
- 第六章 案例分析

- 6.1 成功案例
- 6.2 失败案例
- 第七章 存在问题与改进方向
 - 7.1 存在问题
 - 7.2 改进方向
 - 多页PPT问答
- 第八章 总结

基于 Qwen2.5-VL 的智能图文问答助手设计与实现

第一章 绪论

1.1 研究背景

近年来，大语言模型（Large Language Model, LLM）在自然语言处理领域取得了突破性进展。然而传统语言模型仅能处理文本信息，无法直接理解图像内容。

随着 CLIP、LLaVA、Qwen-VL 等视觉语言模型的发展，人工智能系统逐渐具备跨模态理解能力，能够同时处理图像和文本输入，实现视觉问答（Visual Question Answering, VQA）、图像描述生成、多模态对话等任务。

视觉问答系统广泛应用于：

- 智能教育
- 智能客服
- 商品检索
- 文档分析
- 辅助办公

因此，构建一套具备图像理解与自然语言交互能力的智能图文问答系统具有较高的研究价值和应用价值。

1.2 项目目标

本项目旨在构建一套基于视觉语言模型的智能图文问答助手，实现以下功能：

- (1) 支持上传图片并进行自然语言问答；
- (2) 支持多轮连续对话；
- (3) 支持自然场景图像理解；
- (4) 支持文档截图与文本密集型图像问答；
- (5) 提供 Web 交互界面；
- (6) 在公开数据集上完成性能评测。

1.3 技术路线

本项目采用如下技术路线：

图片输入



Flask 后端服务



Qwen2.5-VL 模型推理



生成回答



Web 前端展示

同时构建 VQA-v2 与 TextVQA 评测流程，对系统性能进行量化分析。

第二章 相关技术介绍

2.1 视觉问答（VQA）

视觉问答任务要求模型根据图像内容回答用户提出的问题。

典型输入形式如下：

图片： 一张公交车图片

问题： What color is the bus?

答案： Yellow

视觉问答同时涉及：

- 图像理解
- 目标检测
- OCR识别
- 语言生成

属于典型的多模态人工智能任务。

2.2 Qwen2.5-VL 模型

Qwen2.5-VL 是阿里巴巴推出的新一代视觉语言模型。

主要特点：

- 支持图像与文本联合输入
- 支持多轮视觉对话
- 支持 OCR 理解
- 支持复杂视觉推理
- 支持中英文场景

本项目采用 Qwen2.5-VL-7B-Instruct 作为核心推理模型。

2.3 Flask 框架

Flask 是轻量级 Python Web 框架。

在本系统中负责：

- 接收用户上传图片

- 管理会话状态
- 调用模型推理
- 返回回答结果

2.4 Transformers

Transformers 提供：

- 模型加载
- Tokenizer
- Processor
- 推理接口

实现 Qwen2.5-VL 的快速部署。

第三章 系统设计

3.1 系统总体架构

系统采用前后端分离架构。

整体结构如下：

用户



Web界面



Flask服务



会话图像管理模块





返回答案

系统主要包括：

图像输入模块

图像输入模块负责接收用户上传的图片文件，并将图片保存至服务器本地目录。系统支持自然场景图片、商品图片以及文档截图等多种图像类型输入。在用户上传图片后，系统会自动完成图片存储和基础信息读取，为后续模型推理提供视觉输入。

会话管理模块

会话管理模块负责维护用户与系统之间的历史对话信息。系统采用 `chat_history` 数据结构保存用户问题与模型回答，在后续提问时将历史对话与当前问题共同输入模型，从而实现多轮连续对话功能。

此外，为避免不同图片之间的上下文信息相互干扰，系统设计了图片切换机制。当检测到用户上传新的图片时，自动清空历史会话记录并重新建立上下文环境，保证问答结果的准确性。

模型推理模块

模型推理模块是系统的核心组成部分，采用 Qwen2.5-VL-7B-Instruct 作为底层视觉语言模型。

该模块首先利用 Processor 对图像和文本进行预处理，然后通过 Chat Template 构建符合模型要求的输入格式，最后调用模型生成接口完成视觉理解与语言生成任务。模型能够同时处理图像信息和文本信息，实现目标识别、场景理解、文字识别以及基础视觉推理等功能。

前端展示模块

前端展示模块采用 HTML、CSS 和 JavaScript 实现，为用户提供图形化交互界面。用户可以通过浏览器上传图片、输入问题并查看模型回答。

3.2 多轮对话设计

本系统支持基于同一张图片的连续多轮对话。

系统在后端维护全局变量：

```
chat_history = []
```

用于记录用户与模型的历史交互内容。

每次用户提问后，系统会将用户问题加入历史记录：

```
chat_history.append(  
    {  
        "role": "user",  
        "content": question  
    }  
)
```

模型生成回答后：

```
chat_history.append(  
    {  
        "role": "assistant",  
        "content": answer  
    }  
)
```

在模型推理阶段，系统遍历全部历史记录并重新构造消息列表（messages），从而实现上下文连续理解。

例如：

第一轮：

用户：这是什么饮料？

模型：Tokyo Black Porter

第二轮：

用户：它属于什么类型？

模型：Porter 风格黑啤酒

第三轮：

用户：这种啤酒口感如何？

模型：具有较浓的麦芽香气和烘焙风味。

3.3 图片管理机制

系统采用单图片会话管理策略。

后端维护变量：

```
current_image_name = None
```

用于记录当前会话对应的图片。

当检测到用户上传新的图片时：

```
if image.filename != current_image_name:
    current_image_name = image.filename
    chat_history = []
```

系统自动清空历史对话记录。

该设计能够避免不同图片之间的上下文相互干扰。

例如：

图片A：

用户：这是什么饮料？

图片B：

用户：图片里有几个人？

如果不清除历史记录，模型可能错误地将饮料相关信息带入人物识别任务，从而影响回答质量。

因此当前版本采用“一张图片对应一个独立会话”的设计方案。

3.4 系统流程

步骤1：

用户上传图片。

步骤2：

图片保存至 uploads 文件夹。

步骤3：

构建消息格式。

步骤4：

调用 Qwen2.5-VL 推理。

步骤5：

生成回答。

步骤6：

结果返回前端展示。

第四章 系统实现

4.1 模型加载

系统启动时加载：

- Qwen2.5-VL-7B-Instruct

- AutoProcessor

采用：

device_map="auto"

实现自动设备映射。

4.2 Prompt构建与多模态输入实现

Qwen2.5-VL采用统一消息格式组织图像与文本输入。

系统首先构造如下结构：

```
{
  "role": "user",
  "content": [
    {
      "type": "image",
      "image": image_path
    },
    {
      "type": "text",
      "text": question
    }
  ]
}
```

其中：

- image字段表示用户上传图片；
- text字段表示用户提出的问题。

随后调用：

```
processor.apply_chat_template()
```

自动生成符合Qwen2.5-VL格式要求的Prompt。

接着通过：

```
process_vision_info(messages)
```

提取图像输入。

最后调用：

```
model.generate()
```

完成视觉理解与答案生成。

该设计能够同时支持：

- 图像理解
- 文本理解
- 多轮视觉对话

体现了视觉信息与语言信息的深度融合。

4.3 图文问答实现

系统使用消息格式组织输入：

用户消息：

- 图像
- 文本问题

模型消息：

- 历史回答

随后利用：

```
processor.apply_chat_template()
```

构造输入 Prompt。

最终调用：

```
model.generate()
```

完成回答生成。

4.3 Web交互实现

前端采用 HTML + JavaScript 实现。

主要功能：

- 图片上传
- 图片预览
- 聊天气泡显示
- 异步问答请求

后端采用 Flask 实现 REST 接口。

4.4 评测脚本实现

实现：

`evaluate_vqa.py`

用于评测 VQA-v2 数据集。

`evaluate_textvqa.py`

用于评测 TextVQA 数据集。

评测结果自动保存至 CSV 文件。

4.5 推理优化与显存管理

由于Qwen2.5-VL-7B模型参数规模较大，为保证系统能够在单张RTX3090显卡上稳定运行，项目采用了多项显存优化策略。

（1）自动设备映射

模型加载时使用：

```
device_map="auto"
```

自动将模型权重加载到可用GPU设备。

(2) 推理模式运行

在VQA评测过程中：

```
with torch.inference_mode():
```

关闭梯度计算。

相比训练模式能够显著减少显存占用。

(3) 缓存释放

推理完成后：

```
del inputs  
del generated_ids
```

主动删除中间变量。

随后执行：

```
gc.collect()  
torch.cuda.empty_cache()
```

释放显存缓存。

该策略能够有效降低长时间评测过程中显存持续增长的问题。

第五章 实验设计与结果分析

5.1 实验环境

硬件环境：

- GPU：RTX 3090（24GB）

软件环境：

- Ubuntu 20.04
- Python 3.10
- PyTorch
- Transformers
- Flask

5.2 数据集与实验设置

为了验证系统性能，分别在自然场景图像数据集VQA-v2和文本密集型图像数据集TextVQA上进行测试。

VQA-v2

从验证集随机抽取500个样本。

每个样本包含：

- 一张自然场景图片
- 一个问题
- 十个标注答案

系统调用ask_vqa接口完成推理。

TextVQA

从验证集随机抽取200个样本。

每个样本包含：

- 一张包含文本信息的图片

- 一个问题
- 标准答案

系统调用ask_textvqa接口完成推理。

评测结果分别保存至：

- vqa_results.csv
- textvqa_results.csv

便于后续统计与错误分析。

采用准确率（Accuracy）作为评价指标。

VQA-v2：

采用官方 VQA Accuracy。

TextVQA：

采用答案匹配准确率。

5.3 实验结果

数据集	样本数	准确率
VQA-v2	500	85%
TextVQA	200	70.1%

5.4 结果分析

实验结果表明：

- (1) 模型在自然场景图像上的表现优于文档图像；
- (2) 颜色识别和目标识别准确率较高；
- (3) 复杂文字识别能力有限；
- (4) 复杂推理任务仍存在错误。

第六章 案例分析

6.1 成功案例

案例1：



船上的文字是什么

船上的文字是“E-820 CR MS 815 AJ”。

这是什么意思

这是一艘船的登记信息。通常，这样的标记包含以下内容：

- **E-820 CR**：可能是船的注册编号或识别码。
- **MS 815 AJ**：可能是船的型号、制造商或其他特定标识。

这些信息用于船只的管理和识别，确保船只在水上活动时遵守相关法规和规定。

分析：

模型能够准确识别图片中的文字并且进行推理回复。

案例2：

浏览... 微信图片_20260610153536_537_12.png



2. **第二阶段**：党的十八大以来。

- 总书记多次强调“为民造福是最大政绩”，强调要坚持立党为公、执政为民，反对急功近利、脱离实际，反对搞劳民伤财的“形象工程”、“政绩工程”。这说明正确政绩观不是临时提出的新要求，而是新时代全面从严治党和推动高质量发展中的一项长期重要要求。

3. **第三阶段**：新中国成立以来。

- 新中国成立以来特别是20世纪50年代末到60年代前期党在社会主义建设实践中形成的经验和教训。一方面，有焦裕禄为代表的正确政绩观；另一方面，“大跃进”时期也带来了深刻教训。

整体来看，PPT强调了正确政绩观的重要性，并回顾了历史上的经验和教训，旨在推动党员干部树立正确的政绩观

分析一下布局

这张PPT的布局设计清晰明了，通过不同的颜色块和箭头引导观众关注重点内容。以下是对布局的详细分析：

1. 标题部分

- **标题**：“学习背景”

请输入问题...

发送

分析：

模型能够识别ppt信息并根据信息回答。

6.2 失败案例

案例1：



这张图片由四张不同的照片拼接而成，每张照片展示的是同一个人在不同时间点的动作。因此，总共是四张图片。

第一张图片和第四张图片中的人物穿着一样们

您说得对。在这四张图片中，第一张和第四张图片中的男子穿着相同的衣服：一件白色T恤和红色短裤。

第二张和第三张呢

第二张和第三张图片中的男子也穿着相似的服装：一件白色T恤和红色短裤。

具体描述一下第一张图片的

第一张图片显示了一位穿着白色T恤和红色短裤的男子正在户外活动。他似乎在进行某种运动或游戏，可能是在投掷一个白色的飞盘。背景是一片草地，周围有树木和一些模糊的建筑物，可能是公园或类似的开放空间。天空看起来有些阴沉，但光线充足。

请输入问题...

发送

回答错误。

原因：

多区域视觉定位错误和错误传播

案例2：



图片里是什么鸟

这张图片中的鸟是太平鸟（学名：Bombycilla garrulus），也被称为蜡嘴雀。太平鸟是一种小型鸣禽，常见于欧亚大陆的温带地区。它们通常有灰色的身体、白色的腹部和黄色的喙尖。太平鸟在冬季会迁徙到温暖的地方过冬，并且喜欢栖息在森林、灌木丛和花园中。图片中可以看到几只太平鸟停在树枝上，其中一只似乎正在啄食树枝上的食物。

总共有几只

图片中有六只鸟。

请输入问题...

发送

原因：

模型将视觉输入错误地映射到了语义数字上

案例3：



提取图片中的文字

文明施工
上海建工集团总公司
上
轮
管
不扰民
不扰民
不扰民
上

请输入问题...

发送

原因：

模型在处理复杂文字时的能力较弱。

第七章 存在问题与改进方向

7.1 存在问题

当前系统存在以下不足：

- (1) 推理速度较慢；
- (2) 复杂OCR场景表现有限；

- (3) 长对话上下文管理能力不足；
- (4) 复杂图表推理能力有待提升。

7.2 改进方向


多页PPT问答

当前系统仅支持单张图片问答。

对于课程讲义、PPT等长文档场景，用户的问题可能同时涉及多个页面内容。

未来计划引入“最近图片缓存+历史页面摘要”的多模态记忆机制。

具体流程如下：



该方案能够在有限显存条件下支持跨页问答和长文档分析，进一步提升系统实用性。

同时，该模块也是本项目下一阶段的重要扩展方向

第八章 总结

本文基于 Qwen2.5-VL 构建了一套智能图文问答助手系统，实现了图像上传、多轮对话和视觉问答等功能，并设计了完整的 Web 交互界面。

实验结果表明，系统能够较好地完成自然场景图像和文档图像的问答任务，在物体识别、颜色判断和简单文本识别方面具有较高准确率。

未来将进一步引入 多页文档记忆机制，提高系统在复杂文档分析和跨页推理场景中的应用能力。